Silent Voice — Definição do MVP v0.1

1. Objetivo do MVP

Demonstrar que é possível reconhecer um conjunto reduzido de palavras por meio da combinação de:

- dois sinais musculares EMG;
- movimentos labiais captados por câmera;
- processamento em um celular Android;
- reprodução da palavra reconhecida em um alto-falante integrado ao dispositivo.

O MVP será treinado inicialmente para **um único usuário**, em ambiente controlado.

---

2. Vocabulário inicial

O primeiro modelo trabalhará com cinco palavras:

- Sim
- Não
- Água
- Ajuda
- Dor

Essas palavras possuem utilidade prática e permitem verificar se o sistema consegue diferenciar padrões musculares e movimentos labiais.

O sistema também deverá reconhecer o estado:

- Nenhuma intenção de fala

Esse estado é importante para impedir que movimentos normais sejam transformados em voz.

---

3. Funcionamento esperado

1. O usuário ativa a captura por um botão físico.
2. O ESP32-S3 coleta os dois sinais EMG.
3. O Raspberry Pi captura o rosto e o áudio ambiente.
4. O Raspberry sincroniza os dados e os envia ao celular por cabo USB.
5. O celular executa:
6. classificação dos sinais EMG;
7. classificação dos movimentos labiais;
8. combinação dos resultados;
9. síntese da palavra escolhida.
10. O celular devolve o áudio ao Raspberry.

11. O Raspberry reproduz o áudio no alto-falante.

No MVP inicial, o botão físico será a principal proteção contra falas acidentais. Confirmação por piscadas poderá ser adicionada posteriormente.

---

4. Arquitetura de hardware

```
2 sensores MyoWare
        ↓
    ESP32-S3
        ↓ UART
Raspberry Pi Zero 2 W
 ├─ câmera CSI
 ├─ microfone I2S
 ├─ botão de ativação
 └─ amplificador + alto-falante
        ↓ USB
 Celular Android
        ↓ USB
Raspberry Pi → alto-falante
```

Ajuste importante

A comunicação entre ESP32-S3 e Raspberry Pi deverá utilizar **UART pelos GPIOs**, e não USB.

O Raspberry Pi Zero 2 W possui somente uma porta USB OTG, que será reservada para a comunicação com o celular. Ele também possui uma entrada CSI-2 própria para câmera.

---

5. Responsabilidade de cada unidade

ESP32-S3

- alimentar e ler os dois sensores EMG;
- amostrar os sinais continuamente;
- aplicar filtragem básica;
- marcar cada amostra com tempo;
- enviar os dados por UART ao Raspberry.

O ESP32-S3 possui ADC com modo contínuo e transferência por DMA, adequado para aquisição periódica dos canais analógicos.

No primeiro teste será utilizada a saída **Envelope** dos MyoWare. Depois, poderá ser avaliada a saída **Raw**, que contém mais detalhes, mas exige processamento e filtragem mais avançados. O MyoWare oferece saídas envelope, retificada e bruta.

Raspberry Pi Zero 2 W

- receber os sinais do ESP32 por UART;
- capturar frames da câmera;
- captar o áudio ambiente;
- manter o buffer dos últimos 10 segundos;
- sincronizar EMG, vídeo e áudio;
- trocar dados com o celular por USB;
- receber o áudio sintetizado;
- reproduzir o áudio no alto-falante.

Celular Android

- executar o modelo de classificação EMG;
- executar o modelo de movimentos labiais;
- combinar as probabilidades dos modelos;
- rejeitar resultados com baixa confiança;
- gerar a voz por text-to-speech;
- devolver o áudio ao Raspberry.

O Android possui APIs para identificar e se comunicar com dispositivos USB quando funciona como host.

---

6. Fusão multimodal do MVP

Cada modelo produzirá uma lista de probabilidades.

Exemplo:

```
EMG:
Água: 70%
Ajuda: 20%
Outros: 10%

Leitura labial:
Água: 80%
Ajuda: 10%
Outros: 10%
```

A fusão multimodal combinará os dois resultados:

```
Resultado final:
Água: 75%
```

A palavra somente será pronunciada quando:

- houver ativação manual;
- EMG e leitura labial tiverem resultados compatíveis;

- a confiança final ultrapassar o limite definido.

Caso contrário, o sistema deverá permanecer em silêncio ou solicitar uma nova tentativa.

---

7. Contexto dos últimos 10 segundos

No primeiro estágio, o Raspberry apenas deverá:

- captar o áudio;
- manter os últimos 10 segundos em memória;
- substituir continuamente o trecho mais antigo;
- enviar o trecho ao celular quando ocorrer uma tentativa de fala.

A utilização desse áudio para corrigir ou priorizar palavras ficará para a segunda versão do MVP. Primeiro será necessário comprovar que EMG e leitura labial funcionam separadamente.

---

8. Componentes do MVP

Processamento

- 1 ESP32-S3 N16R8;
- 1 Raspberry Pi Zero 2 W;
- 1 cartão microSD de 32 GB;
- 1 celular Android compatível com USB OTG.

O ESP32-S3 N16R8 oferece 16 MB de flash e 8 MB de PSRAM, enquanto o Raspberry Pi Zero 2 W possui processador quad-core, 512 MB de RAM, CSI-2 e USB OTG.

EMG

- 2 sensores MyoWare 2.0;
- eletrodos adesivos;
- cabos curtos para conexão;
- alimentação por bateria;
- botão de ativação.

O posicionamento dos sensores será definido experimentalmente, pois a orientação e o músculo escolhido afetam diretamente a qualidade do sinal.

Visão

Para o primeiro protótipo:

- 1 câmera CSI 5 MP compatível com Raspberry Pi Zero;
- cabo flat específico para o conector menor do Pi Zero;
- suporte ajustável para posicionamento diante da boca.

Como a distância entre câmera e boca será praticamente fixa, uma câmera simples poderá ser testada antes da compra de uma câmera com autofocus.

Caso a imagem não possua nitidez suficiente, o upgrade recomendado será a Raspberry Pi Camera Module 3, que possui sensor de 12 MP e autofocus.

Áudio

Entrada:

- 1 microfone digital I2S INMP441 ou equivalente.

Saída:

- 1 amplificador I2S MAX98357A;
- 1 alto-falante de 4 Ω e aproximadamente 3 W.

O INMP441 fornece áudio digital por interface I2S. O MAX98357A recebe áudio I2S e consegue alimentar diretamente um pequeno alto-falante, sendo compatível com placas Raspberry Pi sem saída analógica, como o Pi Zero.

Alimentação e montagem

Para o protótipo de bancada:

- power bank para o Raspberry;
- bateria separada para ESP32 e sensores;
- protoboard ou placa perfurada;
- conectores;
- cabos;
- botão físico;
- suporte provisório impresso em 3D.

A bateria Li-Po definitiva e a placa de gerenciamento de energia devem ser escolhidas somente depois de medir o consumo real.

---

9. Orçamento reservado

- ESP32-S3: até R$ 120
- Raspberry Pi Zero 2 W: até R$ 350
- Dois MyoWare: até R$ 500
- Câmera e cabo CSI: até R$ 100
- Microfone I2S: até R$ 50
- Amplificador e alto-falante: até R$ 70
- Cartão microSD: até R$ 60
- Eletrodos: até R$ 80
- Alimentação, cabos e conectores: até R$ 150
- Estrutura e imprevistos: até R$ 20

Teto planejado: R$ 1.500

Esses valores são limites internos de compra, e não preços definitivos. Cada item deverá ser validado antes da aquisição.

10. Dataset inicial

Para cada uma das cinco palavras:

- 50 repetições por sessão;
- 3 sessões em dias ou horários diferentes;
- 150 amostras por palavra;
- 750 amostras totais.

Cada amostra deverá conter:

- sinal do EMG 1;
- sinal do EMG 2;
- sequência de vídeo da boca;
- horário de início e fim;
- palavra pronunciada silenciosamente;
- indicação de amostra válida ou inválida.

Também deverão ser gravadas amostras de repouso, mastigação, engolir e movimentos naturais para ensinar o sistema a permanecer em silêncio.

---

11. Critérios de sucesso

O MVP será considerado funcional quando:

- os dois canais EMG forem capturados de forma estável;
- o vídeo e o EMG estiverem sincronizados;
- o celular receber e devolver dados pelo cabo;
- pelo menos cinco palavras forem classificadas;
- o sistema reconhecer repouso e movimentos não intencionais;
- a palavra reconhecida for reproduzida no alto-falante;
- o sistema não emitir voz sem ativação;
- a precisão inicial atingir pelo menos 70% em testes separados do treinamento;
- o fluxo completo funcionar sem internet ou Wi-Fi.

A latência inicial poderá ser de até aproximadamente três segundos. Ela será otimizada somente depois que o funcionamento básico for comprovado.

---

12. Fora do escopo inicial

Não fazem parte da primeira versão:

- frases livres;
- vocabulário ilimitado;
- voz clonada do usuário;
- reconhecimento para vários usuários;
- processamento integral no ESP32;

- correção por Tiny-BERT;
- funcionamento clínico;
- miniaturização definitiva;
- bateria integrada final;
- confirmação por piscadas;
- latência inferior a 200 ms.

---

13. Regra de segurança

Durante testes com eletrodos na pele:

- todo o conjunto deverá funcionar por bateria;
- o celular não poderá estar carregando na tomada;
- o Raspberry não poderá estar ligado a fonte de bancada ou computador conectado à rede elétrica;
- os eletrodos deverão ser removidos antes de carregar qualquer bateria;
- o projeto será tratado como protótipo educacional, não como equipamento médico.

A própria fabricante recomenda alimentação por bateria para obter sinal mais limpo e eliminar a possibilidade de criar um caminho perigoso de corrente até a rede elétrica.