Silent Voice — Experimento 03: Captura e Classificação dos Movimentos Labiais

1. Objetivo

Verificar se uma câmera integrada ao dispositivo consegue:

- manter a boca enquadrada durante o uso;
- registrar movimentos labiais com qualidade;
- localizar automaticamente a região da boca;
- diferenciar visualmente as palavras “Sim”, “Não” e “Água”;
- reconhecer quando não existe tentativa de fala.

Neste experimento, o treinamento será realizado inicialmente em um computador.

---

2. Hipótese

Palavras diferentes produzem sequências visuais distintas de abertura, fechamento e movimentação dos lábios.

A câmera não identificará diretamente a palavra. Ela fornecerá uma sequência de imagens para um modelo treinado especificamente com o usuário.

---

3. Hardware necessário

- 1 Raspberry Pi Zero 2 W;
- 1 câmera CSI compatível;
- 1 cabo CSI específico para Raspberry Pi Zero;
- 1 cartão microSD;
- 1 power bank;
- 1 suporte ajustável;
- iluminação branca difusa opcional;
- computador para organização e treinamento do dataset.

Os sensores EMG não serão necessários durante a primeira fase deste experimento.

---

4. Câmera recomendada

A principal candidata será:

```
Raspberry Pi Camera Module 3 – Standard
```

Motivos:

- sensor de aproximadamente 12 MP;
- foco automático;
- integração oficial com Raspberry Pi;
- dimensões compactas;
- maior capacidade de adaptação a pequenas mudanças na distância da boca.

A Camera Module 3 possui sensor IMX708 e autofocus. A versão Standard é mais apropriada que a Wide porque o dispositivo precisa observar principalmente a boca, e não uma área ampla ao redor do usuário.

A versão NoIR não será necessária no MVP, pois os testes ocorrerão com iluminação visível normal.

Uma câmera mais barata poderá ser utilizada inicialmente para testes de software, mas a compra deverá garantir:

- compatibilidade com o conector CSI do Pi Zero;
- disponibilidade do cabo correto;
- foco adequado na distância planejada;
- funcionamento com o sistema atual de câmera do Raspberry Pi.

---

5. Software de captura

O Raspberry utilizará:

- Raspberry Pi OS;
- `rpicam-apps`;
- Picamera2;
- Python;
- OpenCV para manipulação das imagens.

O Picamera2 é a interface Python atual para o sistema de câmeras baseado em `libcamera`. O antigo conjunto `raspivid`, `raspistill` e Picamera legado não deverá ser utilizado.

---

6. Arquitetura do experimento

```
Movimento da boca
        ↓
Câmera CSI
        ↓
Raspberry Pi Zero 2 W
        ↓
Gravação de pequenos vídeos
        ↓
Transferência para computador
        ↓
```

```
Detecção da boca
        ↓
Treinamento e avaliação
```

Neste momento, os vídeos poderão ser transferidos manualmente para o computador.

A comunicação Raspberry–celular ainda não será necessária.

---

7. Posicionamento da câmera

A câmera deverá ficar:

- centralizada em relação à boca;
- levemente abaixo ou à frente do queixo;
- sem obstruir a visão do usuário;
- com suporte ajustável;
- mantendo distância aproximadamente constante.

Serão testadas inicialmente três distâncias:

```
10 cm
15 cm
20 cm
```

Para cada distância, avaliar:

- nitidez dos lábios;
- enquadramento;
- conforto;
- movimentação da estrutura;
- presença do nariz e do queixo na imagem;
- estabilidade durante movimentos da cabeça.

A distância de 15 cm será apenas o ponto inicial, não uma decisão definitiva.

---

8. Configuração inicial de vídeo

Configuração sugerida:

```
Resolução: 640 × 480
Taxa: 30 frames por segundo
Formato de gravação: MP4 ou sequência de frames
Duração: aproximadamente 2 segundos por tentativa
```

Não é necessário utilizar toda a resolução da câmera durante o treinamento inicial.

Uma resolução menor:

- reduz o tamanho dos arquivos;
- diminui o processamento;
- facilita a transmissão futura ao celular;
- ainda permite recortar a região da boca.

A câmera deverá registrar uma imagem maior do rosto e posteriormente recortar apenas a boca.

---

9. Controle da imagem

Antes da coleta definitiva, deverão ser ajustados:

- foco;
- exposição;
- balanço de branco;
- brilho;
- posição;
- iluminação.

Sempre que possível, esses parâmetros deverão permanecer fixos durante uma sessão.

Mudanças automáticas muito grandes de foco ou exposição podem fazer o modelo aprender diferenças da câmera, em vez dos movimentos labiais.

---

10. Localização da boca

O MediaPipe Face Landmarker será utilizado para:

- localizar o rosto;
- encontrar pontos de referência faciais;
- identificar a região aproximada dos lábios;
- acompanhar o movimento da boca;
- produzir um recorte padronizado.

O Face Landmarker detecta landmarks faciais, mas não executa leitura labial nem identifica palavras por conta própria.

Fluxo:

```
Frame completo
      ↓
Detecção do rosto
      ↓
Localização dos lábios
      ↓
Recorte da boca
```

```
      ↓
Redimensionamento
      ↓
Sequência visual
```

Cada recorte poderá ser redimensionado inicialmente para:

```
96 × 96 ou 112 × 112 pixels
```

---

11. Classes iniciais

Utilizar as mesmas palavras do Experimento 02:

- Sim;
- Não;
- Água;
- Repouso;
- Movimento não intencional.

Movimentos não intencionais podem incluir:

- bocejar;
- sorrir;
- abrir a boca;
- movimentar a língua;
- engolir;
- movimentar a cabeça;
- ajustar os lábios sem tentar falar.

---

12. Dataset inicial

Realizar três sessões em momentos diferentes.

Em cada sessão:

- 40 repetições de “Sim”;
- 40 repetições de “Não”;
- 40 repetições de “Água”;
- 40 registros de repouso;
- 20 movimentos não intencionais.

Total:

```
180 vídeos por sessão
540 vídeos no total
```

Cada gravação deverá conter aproximadamente:

```
1 segundo antes da articulação
2 segundos de tentativa
1 segundo depois
```

O vídeo poderá ser recortado posteriormente.

---

13. Protocolo de gravação

Para cada amostra:

1. Permanecer com o rosto em repouso.
2. Iniciar a gravação.
3. Articular silenciosamente a palavra.
4. Permanecer novamente em repouso.
5. Encerrar a gravação.
6. Verificar se o vídeo foi salvo corretamente.

A ordem das palavras deverá ser alternada.

Exemplo:

```
Não → Repouso → Água → Movimento → Sim
```

O usuário não deverá exagerar artificialmente a movimentação dos lábios, exceto em uma coleta separada destinada a comparar articulação natural e articulação reforçada.

---

14. Organização dos arquivos

Estrutura sugerida:

```
visual_dataset/
├── sessao_01/
│   ├── sim/
│   │   ├── sim_001.mp4
│   │   └── sim_002.mp4
│   ├── nao/
│   ├── agua/
│   ├── repouso/
```

```
│   ├── movimento/
│   └── metadata.json
├── sessao_02/
└── sessao_03/
```

Metadados:

```
classe
sessao
repeticao
distancia_camera
resolucao
fps
iluminacao
data
observacoes
amostra_valida
```

---

15. Primeira abordagem de classificação

A primeira abordagem utilizará os pontos dos lábios fornecidos pelo MediaPipe.

Características possíveis:

- largura da boca;
- altura da abertura;
- distância entre os lábios;
- proporção largura/altura;
- deslocamento dos cantos da boca;
- velocidade de abertura;
- duração dos movimentos;
- sequência temporal dessas medidas.

Esses dados poderão alimentar modelos simples, como:

- Random Forest;
- Support Vector Machine;
- k-Nearest Neighbors.

Essa abordagem será utilizada como baseline por ser mais simples e permitir verificar rapidamente se as palavras apresentam movimentos diferentes.

---

16. Segunda abordagem

Caso os landmarks não sejam suficientes, será utilizado diretamente o vídeo recortado da boca.

Fluxo:

```
Sequência de frames da boca
        ↓
Extrator visual
        ↓
Modelo temporal
        ↓
Probabilidades das palavras
```

O modelo poderá combinar:

- uma CNN leve para analisar cada frame;
- uma camada temporal para analisar a ordem dos movimentos.

Somente um modelo que apresente bons resultados no computador será convertido para execução no Android. O TensorFlow Lite permite executar modelos convertidos diretamente em dispositivos Android.

---

17. Separação do dataset

Assim como no EMG, não será utilizada apenas uma divisão aleatória.

Estratégia:

```
Sessões 1 e 2 → treinamento
Sessão 3 → teste
```

Depois:

```
Sessões 1 e 3 → treinamento
Sessão 2 → teste
```

Isso verifica se o modelo continua funcionando em uma gravação feita em outro momento.

---

18. Avaliação

Serão analisados:

- acurácia geral;
- precisão;
- recall;
- F1-score;
- matriz de confusão;

- taxa de falhas na localização da boca;
- falsos reconhecimentos durante o repouso;
- diferença de desempenho entre distâncias;
- diferença de desempenho entre iluminações.

O erro mais grave será interpretar repouso ou movimento normal como uma palavra.

---

19. Critérios de aprovação

O Experimento 03 será aprovado quando:

- a câmera mantiver a boca visível durante os testes;
- a região dos lábios for localizada na maioria dos frames;
- os vídeos forem gravados sem travamentos frequentes;
- o recorte da boca permanecer estável;
- ao menos duas palavras apresentarem padrões visuais diferenciáveis;
- a classificação da sessão de teste atingir aproximadamente 70% ou mais;
- o repouso apresentar recall mínimo de 90%;
- os movimentos não intencionais raramente forem classificados como palavras.

Uma precisão inferior a 70% não invalida a câmera, pois o resultado posteriormente será combinado com o EMG.

---

20. Possíveis resultados

Resultado A — Boa classificação visual

As três palavras são diferenciadas.

Próxima ação:

```
Sincronizar vídeo e EMG
```

Resultado B — Algumas palavras são visualmente semelhantes

Será possível:

- substituir palavras;
- aumentar o dataset;
- utilizar os frames recortados;
- alterar o posicionamento da câmera;
- combinar o resultado com o EMG.

Resultado C — Problemas de foco ou iluminação

Será necessário:

- alterar a distância;
- melhorar a iluminação;
- fixar parâmetros da câmera;
- ajustar o suporte;
- avaliar uma câmera com autofocus.

Resultado D — Movimento da cabeça prejudica o recorte

Será necessário:

- ampliar um pouco o enquadramento;
- estabilizar o suporte;
- utilizar landmarks para corrigir rotação;
- incluir pequenas movimentações no dataset.

---

21. Privacidade

Os vídeos conterão dados faciais do usuário.

Portanto:

- deverão ser armazenados localmente;
- não deverão ser publicados sem autorização;
- deverão possuir identificação anônima;
- deverão ser acessados somente pela equipe;
- participantes adicionais deverão fornecer consentimento.

No MVP, o treinamento continuará restrito a um único usuário.

---

22. Entregáveis

Ao final deverão existir:

- definição da câmera escolhida;
- distância e ângulo recomendados;
- suporte provisório;
- script de captura com Picamera2;
- dataset visual organizado;
- script para localizar e recortar a boca;
- arquivos de landmarks;
- modelo visual inicial;
- matriz de confusão;
- análise das condições de iluminação;
- conclusão sobre a viabilidade da leitura labial.

23. Próxima etapa

Após a aprovação:

```
Experimento 04 — Sincronização de EMG e Vídeo
```

O objetivo será registrar sinais musculares e movimentos labiais da mesma tentativa, utilizando timestamps comuns e preparando os dados para a primeira fusão multimodal.